


СТАТИСТИКА



Време за някои дефиниции

Популация: Групата, която притежава изучаваната характеристика

Индивид : всеки член на популацията

Извадка - подмножество на популацията

Броят n на елементите на извадката се нарича **обем** на извадката.


Пример: Изучаване въздействието на аспирина

Популация: всички хора от дадена възрастова група

Индивид : всеки човек

Извадка : избират се само 100 човека и се наблюдават

100= обем на извадката



ВАЖНО

Всички **числови характеристики на популацията** се наричат **параметри** (те са точно определени константи, които могат да бъдат известни или неизвестни). Например популационна средна стойност, популационна дисперсия, популационно стандартно отклонение.

Случайните извадки имат свои **числови характеристики**, които зависят от извадката и затова те имат характер на случайни величини. Те се наричат **статистика**. Например, извадкова средна стойност, извадкова дисперсия, извадково стандартно отклонение.

Средна стойност

- Ако описва популацията, се нарича популационна средна стойност и се означава с μ (параметър)
- Ако описва извадката се нарича извадково средно и се означава с $\bar{X}$ (статистика)

Формула

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

$X_1, X_2, X_3, \dots, X_n$

Стойностите от данните

Пример: Случайно избрани студенти, взели даден тест, са получили следните точки **14, 15, 17, 16, 15**

Тогава средният им брой точки е извадково средно

$$\bar{X} = \frac{\Sigma X}{n} = \frac{14 + \dots + 15}{5} = \frac{77}{5} = 15,4$$

Дисперсия

- Ако описва популацията, се нарича популационна дисперсия и се означава с σ^2 (параметър)
- Ако описва извадката се нарича извадкова дисперсия и се означава с s^2 (статистика)

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Или когато е дадено честотно разпределение

$$s^2 = \frac{\sum_{i=1}^k (x_i - \bar{x})^2 p_i}{n - 1}$$

Стандартно отклонение

- Ако описва популацията, се нарича популационна дисперсия и се означава с **σ (параметър)**
- Ако описва извадката се нарича извадкова дисперсия и се означава с **s (статистика)**
- Мерните единици са същите както и мерните единици на данните.
- Измерва отклонението на данните от тяхната средна стойност.

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Нека случайната извадка

$$X_1, X_2, X_3, \dots, X_n$$

с обем n е от нормално разпределена популация със средна стойност μ и дисперия σ^2 , т.е. $N(\mu, \sigma^2)$

Тогава всеки елемент X на извадката, като елемент и на популацията е нормално разпределен със средна стойност μ и дисперия σ^2 , т.е. $N(\mu, \sigma^2)$

ВАЖНО!!!!!!

Извадковото средно е

случайна величина, която е нормално разпределена, т.е.

$$\bar{X} \in N\left(\mu, \frac{\sigma^2}{n}\right)$$

Оценяване на параметри

Точкови оценки На параметри



Точковата оценка е
= статистиката.

Параметър	Статистика
Средна стойност μ	Извадково средно $\bar{x}$
Дисперсия σ^2	Извадкова дисперсия s^2
Вероятност p	Извадкова пропорция $\hat{p}$

Доверителни интервали за параметри

Интервал, построен на основата на извадката, който съдържа неизвестния параметър с вероятност близка до 1

Ниво на доверие

= вероятността с която се доверяваме, че този интервал съдържа неизвестния параметър

Означение: $(1-\alpha)100\%$

примери:

90% дов. инт.,

95% дов. инт.

Доверителен интервал

за популационната средна стойност μ

при известен параметър σ

Направена е извадка с обем n от *нормално разпределение* с *неизвестна* средна стойност μ , и *известно* стандартно отклонение σ

Как да построим $(1-\alpha)\%$ доверителен интервал за μ ?

Точкова оценка на μ е извадковото средно

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Извадковото средно

Формула:

$$\bar{X} - z_{\frac{1-\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\frac{1-\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

Направена е извадка с обем n от *нормално разпределение* с *неизвестна* средна стойност μ , и *известно* стандартно отклонение σ

Как да построим 99% доверителен интервал за μ ?


Намираме извадковото средно

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Формула:

$$\bar{X} - z_{\frac{1-\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\frac{1-\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

Доверителен интервал (а,в) така, че $P(a < \mu < b) = 0,99$



2.5	0.994613830	0.994766365	0.994915046	0.995059954	0.995201171
2.6	0.995975369	0.996092924	0.996207393	0.996318845	0.996427351

намираме точка наляво от която лицето е $0.995 = (1-0.99)/2$

$$z_{\frac{1-\alpha}{2}} = z_{0.995} = 2.52$$

$$\bar{X} - 2,52 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 2,52 \frac{\sigma}{\sqrt{n}}$$

Пример



Нека X е количеството мляко, консумирано от българите дневно. Известно е, че това количество е нормално разпределено със стандартно отклонение 96 г. За да оценят средното количество, Асоциацията на млекопроизводителите е направила случайна извадка от 576 българи и е получила средна стойност 133 грама дневно. Постройте 99% доверителен интервал.

Точкова оценка на неизвестната средна консумация е извадковото средно, $\bar{x} = 133$

$$133 \pm 2,52 \frac{96}{\sqrt{576}}$$



$$122.92 \leq \mu \leq 143.08$$

Постройте 90% доверителен интервал

$$133 \pm 1,64 \frac{96}{\sqrt{576}}$$



$$126.44 \leq \mu \leq 139.58$$



СРАВНИ

Доверителен интервал

за популационната средна стойност μ

при НЕизвестен параметър σ

Направена е извадка с обем n от *нормално разпределение* с *неизвестна* средна стойност μ , и НЕизвестно стандартно отклонение σ

Как да построим $(1-\alpha)\%$ доверителен интервал за μ ?

Точкова оценка на μ е извадковото средно

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Извадковото средно

Формула:

$$\bar{X} - t_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$$

t-разпределение




Подобно на стандартното нормално разпределение графиката на плътността е камбанка с център 0.

Но t-разпределение има **степени на свобода** и друга таблица от стойности

Степените на свобода = $n-1$
=обем на извадката -1

Нормалната крива е симетрична относно μ и общата ѝ площ под кривата над Ох е 1



ПРИЛОЖЕНИЕ 2

Квантили $t_q(k)$ на симетричното t - разпределение на Стюдънт

$k \backslash q$	0.60	0.75	0.90	0.95	0.975
1	0.324919256	1.000000793	3.077684596	6.313748599	12.706150301
2	0.288674755	0.816496595	1.885618985	2.919987310	4.302655725
3	0.276670562	0.764891865	1.637745299	2.353363016	3.182449291
4	0.270722467	0.740697033	1.533205705	2.131846486	2.776450856
5	0.267181122	0.726686835	1.475884801	2.015049176	2.570577635
6	0.264834625	0.717558351	1.439755124	1.943180905	2.446913641
7	0.263166839	0.711141865	1.414923645	1.894577508	2.364622560
8	0.261920832	0.706386345	1.396815605	1.859548320	2.306005626
9	0.260955630	0.702722218	1.383028803	1.833113856	2.262158887
10	0.260184834	0.699811835	1.372184215	1.812461505	2.228139238
11	0.259556145	0.697444875	1.363430329	1.795883691	2.200986273
12	0.259032618	0.695482640	1.356218036	1.782286745	2.178812792
∞	0.253346570	0.674490366	1.281550794	1.644853000	1.959961082

Дава лицето наляво от съответната точка,, т.е. $P(T < a) = q$ при степени на свобода k

Например, нека степените на свобода на t -разпределението са $k=6$, тогава $P(T < 1.439755124) = 0.9$

Доверителен интервал за средна стойност μ (σ НЕизвестно)

Направена извадка с обем n от *нормално разпределение* с *неизвестна* средна стойност μ , и *НЕизвестно* стандартно отклонение σ

Формула

$$\bar{X} - t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}}$$



Пример



Нека X е количеството мляко, консумирано от българите дневно. Известно е, че това количество е нормално разпределено. За да оценят средното количество, Асоциацията на млекопроизводителите е направила случайна извадка от 9 българи и е получила средна стойност 133 грама дневно и стандартно отклонение 96 г. Постройте 99% доверителен интервал.

96 грама е извадковото стандартно отклонение

$$\bar{X} - t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{\frac{\alpha}{2}, n-1} \frac{s}{\sqrt{n}}$$

$$t_{\frac{\alpha}{2}, n-1} = t_{0.995, 8} = 3.355$$

$$133 - 3.355 \frac{96}{\sqrt{9}} \leq \mu \leq 133 + 3.355 \frac{96}{\sqrt{9}}$$

$$25.64 \leq \mu \leq 240.36$$

Самостоятелна работа (представи отговора в classroom. Време за работа 5 мин.)

Министерството на образованието решава да тества дали учениците със завършено начално образование могат да четат средно поне 150 думи в минута. Избрани са по случаен начин 200 ученици, завършващи средното си образование и на всеки ученик е даден да прочете един и същ текст, като е измерено времето. Намерено е, че средно тези ученици четат по 156 думи в минута, а стандартното отклонение на извадката е 18 думи.


Числото 156 в статистиката се нарича

- А/ средна стойност
- Б/ извадкова средна стойност
- В/ среден брой думи
- Г/ нито едно от изброените

Тестване на хипотези

Използваме случайна извадка за да научим нещо за популацията

популация



Вярвам, че средната възраст е 50 (хипотеза).

Случайна извадка

средно $\bar{X} = 20$

Не приемам хипотезата! Никак не си близо до истината.




Какво е хипотеза?

Недоказано твърдение за популационния параметър

Параметър е числова характеристика на популацията. Може да бъде:

- Популационна средна стойност,
- Популационна пропорция,
- Популационна дисперсия

Вярвам, че средния успех по ТВиПС е 5.00



•Пример: Верно ли е, че средната седмична сума, която студентите дават за алкохол е 10 лв?

Обща идея за тестване на хипотези

Първо, формулираме две хипотези за

Нулева хипотеза


- “Убеждението” което подлежи на тестване
- Винаги съдържа знаците : $=$, $\leq$, или $\geq$
- Означение: H_0

Алтернативна хипотеза

- Противоположна на нулевата хипотеза
- Винаги съдържа знаците: $\neq$, $<$, or $>$
- Означение H_1

Пример:

$$H_0: \mu \geq 3 \quad H_1: \mu < 3$$



Тестване на хипотези

В статистиката винаги се предполага, че нулевата хипотеза е верна.

Тогава, решението се основава на съществуването на достатъчно основание

- Ако има достатъчно основание, то
отхвърляме нулевата хипотеза
- Ако няма достатъчно основание,
не отхвърляме нулевата хипотеза.

Ако нулевата хипотеза се отхвърли, то понякога на практика се казва, че резултатите **потвърждават** алтернативната хипотеза. Но това от статистическа гледна точка не е верно.

ВАЖНО

- В статистиката никога не можем да
- **докажем** едно или друго твърдение.
- Можем само да заключим, че има **достатъчно основание** да отхвърлим едно твърдение.
- В статистиката няма значение какво решение вземаме, винаги има **шанс от грешки! Вероятността да отхвърлим верна хипотеза се нарича **ниво на****

Основни идеи за тестване

Критична област $\Rightarrow$ **Област на отхвърляне**

Ниво на значимост

Означение α

Избираме α

$\Rightarrow$ Типични стойности

0,01

0,05

0,1

Построяваме област на отхвърляне (критична област),
така че лицето над нея под кривата на плътността $=\alpha$

ОСНОВНИ ИДЕИ

$$H_0: \mu = 12$$

$$H_1: \mu < 12$$

Ще отхвърлим нулевата, ако извадковото средно е много малко в сравнение с 12

1 начин: Построяваме независимо от извадката област от вида $(-\infty, a)$, която е област на отхвърляне, т.е. лицето над този интервал е избраното от нас число α

Малко вероятно е да получим извадково средно 1



Тестване на хипотези относно популационната средна стойност μ

Видове тестове $H_0: \mu = \text{константа}$

Зависи от вида на алтернативната хипотеза

Едностранинен тест

$H_1: \mu < \text{константа}$

Лявостранинен тест

или

$H_1: \mu > \text{константа}$

дясностранинен тест

Двустранинен тест

$H_1: \mu \neq \text{константа}$

еквивалентно на

$H_1: \mu > \text{константа}$

$\mu < \text{константа}$

Алгоритъм за тестване на хипотези

критична област

1. Напишете нулевата H_0 и алтернативната H_1 хипотеза
2. Определете нивото на значимост α
3. Определете статистиката и извадковото разпр.
4. Получете критичната област
5. Направете извод
6. Интерпретация на извода

Тестване на хипотези за неизвестното популационно средно μ (σ е известно)

Предположения

- Популацията е нормално разпределена
- Ако не е нормална, то при голям обем на извадката (ЦГТ) можем да апроксимираме с нормална ($n \geq 30$)
- Популационната дисперсия (станд.откл.)
 σ^2 е известно


• Използваме Z-статистиката

$$Z = \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Двустранен Z –тест за средното μ (σ Известно)

$$H_0: \mu = c \quad H_1: \mu \neq c \quad \text{---} \text{ (означава } < \text{ или } > \text{)}$$

Избираме ниво на значимост α



Критична област при двустранен Z – тест за средното μ (σ Известно)

Използваме избраното от нас ниво на значимост α ,
за да намерим

Критичната област се състои от два интервала (два клона)
лицето над които е - α

Как се взема решение

Ако статистиката $Z = \frac{\bar{X} - \mu}{\sigma} \sqrt{n}$ за конкретната извадка

- има стойност в критичната област – то отхвърляме H_0
- ако стойността ѝ е извън КО – няма основание да отхвърлим H_0

Пример

Дали средно всяка кутия съдържа 368 грама?

Направена е случайна извадка от 25 кутии, които са претеглени и е получено средното им тегло : 372,5 грама.

Компанията знае от предварителни наблюдения, че теглото е нормално разпределено със стандартно отклонение 15 грама. Тествайте с ниво на значимост 0,05.



Решение



1. Напишете нулевата и алтернативната хипотеза

$H_0: \mu = 368$

$H_1: \mu \neq 368$

Двустранен тест

2. Ниво на значимост

$$\alpha = 0,05$$

3. Статистика и извадково разпределение

$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{372,5 - 368}{\frac{15}{\sqrt{25}}} = +1,50$$


теглото е нормално разпределено
със стандартно отклонение 15,
т.е. $\sigma=15$

4. Критична област

Критичната област е $(-\infty, -1,96)$ и $(1,96, +\infty)$.

$$\alpha = 0,05$$

$$\alpha/2 = 0,025$$



5. Извод

$z = 1,50$ не е в критичната област, следователно не отхвърляме H_0

6. Интерпретация

Няма достатъчно основание да отхвърлим твърдението на компанията

че средното тегло е 368

Едностраниен тест за средната стойност μ (σ известно)

- Предположения

- Популацията е нормално разпределена
- Ако не е нормална, можем да я апроксимираме с нормална ($n \geq 30$)

- Алтернативната хипотеза има знаците $<$ или $>$


- Z-статистика

$$Z = \frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$$

Едностраниен Z тест за средна стойност при известно σ


$$H_0: \mu = 0 \quad H_1: \mu < 0$$

Област на
отхвърляне



$$H_0: \mu = 0 \quad H_1: \mu > 0$$

Област на
отхвърляне



Малки стойности не
противоречат на H_0 -
НЕ се отхвърля!

Дали средно всяка кутия съдържа повече от 368 грама? Случайна извадка от 25 кутии има тегло 372,5. Компанията знае, че стандартното отклонение на теглото в кутиите е 15 грама. Тествайте твърдението при ниво на значимост 0,05 като предположете, че популацията е нормална.

Пример



Решение



1. Нулева и алтернативна хипотеза

$$H_0: \mu = 368$$

$$H_1: \mu > 368$$

Дясностранен тест

2. Ниво на значимост

$$\alpha = 0,05$$

3. Статистика и извадково разпределение


$$Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{372,5 - 368}{\frac{15}{\sqrt{25}}} = +1,50$$

Нормална популация, $\sigma = 15$

4. Критична област

Критичната област е $(1,645, +\infty)$.

$$\alpha = 0,05$$



5. Извод

$z = 1,50$ не е в критичната област, затова не отхвърляме H_0

6. Интерпретация

Няма достатъчно основание да отхвърлим твърдението
че средното е повече от 368

Проверка на хипотези за средната стойност μ ,
когато популационната дисперсия е неизвестна
(σ НЕИЗВЕСТНО)

Предположения

- Популацията е нормално разпределена
 - Малък обем ($n \leq 30$)
- Използваме t -разпределение и следната статистика


$$t = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}$$

t-тест за неизвестното
популационно средно

Двустранен Z –тест за средното μ (σ НЕизвестно)

$$H_0: \mu = c \qquad H_1: \mu \neq c \quad \text{---} \text{ (означава } < \text{ или } > \text{)}$$


Избираме ниво на значимост α



Едностраниен Z тест за средна стойност при НЕизвестно σ


$$H_0: \mu = 0 \quad H_1: \mu < 0$$

Област на
отхвърляне



$$H_0: \mu = 0 \quad H_1: \mu > 0$$

Област на
отхвърляне



Малки стойности не
противоречат на H_0 -
НЕ се отхвърля!

Двустранен t тест

Пример

За да се провери дали машината за пълнене е точно настроена и пълни кутиите по 368 грама, се прави случайна извадка от 16 кутии. За тези кутии е намерено, че средното им тегло е 372,5 грама и стандартното отклонение е 12 грама. Знае се, че теглото на кутиите е нормално разпределено. Тествайте твърдението при ниво на съгласие 0,05 .



Решение



1. Нулева и алтернативна хипотеза

$$H_0: \mu = 368$$

$$H_1: \mu \neq 368$$

Двустранен тест

2. Ниво на значимост

$$\alpha = 0,05$$

3. Статистика, извадково разпределение

$$t = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} = \frac{372,5 - 368}{\frac{12}{\sqrt{16}}} = +1.5$$


Използваме t-разпределение

нормално разпределено тегло, σ е неизвестно

4. Критична област

Критичната област е
 $(-\infty, -2,131)$ и $(2,131, +\infty)$.

Използваме $t(15)$



5. Извод

$t=1,5$ не попада в критичната област, затова не отхвърляме хипотезата

6. Интерпретация на извода

Няма достатъчно основание за да отхвърлим твърдението, че средното тегло е 368